

Bases formelles du TAL

corrections d'exercices

Pierre-Léo Bégay

January 30, 2020

Contents

1	Langages	2
1.1	Mots	2
1.2	Langage	5
2	Expressions régulières	6
2.1	Lexique et idée générale	6
2.1.1	Les lettres et ϵ , la base	6
2.1.2	., la concaténation	6
2.1.3	*, l'itération	6
2.1.4	+, la disjonction	6
2.2	Syntaxe	7
2.3	Sémantique	7
2.3.1	Les cas de base	7
2.3.2	Sémantique de la concaténation	7
2.3.3	Sémantique de la disjonction	7
2.3.4	Sémantique de l'itération	7
2.4	Mise en application	7
2.4.1	Quelques astuces	7
2.4.2	Syntaxe en pratique	7

Chapter 1

Langages

1.1 Mots

Exercice 1.1.1. Combien de préfixes et suffixes admet un mot w quelconque ?

Correction. Soit un mot w qui se décompose en $c_1c_2\dots c_n$ avec $\forall i \in [1 - n], c_i \in \Sigma$. Il y a $n + 1$ préfixes : $\epsilon, c_1, c_1c_2, c_1c_2c_3, \dots$, et $c_1\dots c_n$ entier. Pareil pour les suffixes avec $\epsilon, c_n, c_{n-1}c_n, \dots, c_1\dots c_n$. Pour tout mot w , il y a donc $|w| + 1$ préfixes et suffixes.

Exercice 1.1.2. Donner l'ensemble des facteurs du mot $abbba$.

Correction. On note en *rouge* les facteurs :

- $abbba$ (ϵ)
- *abbba*
- *abbba*
- *abbba*
- *abbba*
- *abbba*
- *abbba*
- *abbba*
- *abbba*
 - On saute *abbba* et *abbba*
- *abbba*
 - On saute *abbba*
- *abbba*
 - On saute *abbba*

Exercice 1.1.3. (*) Donner la borne la plus basse possible du nombre de facteurs d'un mot w . Donner un mot d'au moins 3 lettres dont le nombre de facteurs est exactement la borne donnée.

Correction. Soit $w = c_1 \dots c_n$. L'ensemble des **facteurs** de w est l'ensemble des $c_1 \dots c_{i-1} \mathbf{c_i} \dots \mathbf{c_j} c_{j+1} \dots c_n$ ainsi qu' ϵ . Le nombre de ces facteurs non-nuls est borné par

$$|\{(i, j) \mid 0 \leq i < j \leq n\}| = \mathbf{1} + 2 + 3 + \dots + n = \mathbf{2} \frac{n(n+1)}{2} \in O(n^2)$$

Il ne s'agit que d'une borne, puisqu'il y aura des répétitions à partir du moment où une même lettre apparaît deux fois (cf. l'exercice précédent). Duale, le mot abc par exemple contient bien $1 + \frac{3 \times 4}{2} = 7$ facteurs.

Exercice 1.1.4. Montrer que tout facteur d'un mot en est également un sous-mot. A l'inverse, montrer qu'un sous-mot n'est pas forcément un facteur.

Correction. Soit f facteur d'un mot w . D'après la définition, ça veut dire qu'il existe v_1 et v_2 tels que $w = v_1.f.v_2$. On a alors bien $w = v_0.s_0.v_1$ avec $s_0 = f$.

Soit $w = abc$. ac en est clairement un sous-mot, alors qu'il n'en est pas un facteur.

Exercice 1.1.5. Donner toutes les façons de voir $abba$ comme sous-mot de $baaabaabbbaa$.

Correction. On a la liste (beaucoup trop longue (22 éléments !)) suivante :

- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa
- baaabaabbaa

¹Quand i vaut 0, il y a n possibilités pour j . Quand i vaut i , il y a $n - 1$ possibilités pour j et quand i vaut $n - 1$, il y a une possibilité pour j .

²Prouvable assez facilement par induction sur n (bon entraînement si vous n'avez pas l'habitude)

- baabaabbba
- baaabaabbba
- baaabaabbba
- baaabaabbba
- baaabaabbba

Exercice 1.1.6. Donner l'ensemble des sous-mots de *abba*

Correction. On a la liste suivante de **sous-mots** :

- *abba* (€)
- *abba*
- *abba*
- *abba*
 - On saute *abba* et *abba*
- *abba*
- *abba*
 - On saute *abba*
- *abba*
- *abba*
- *abba*
 - On saute *abba* et *abba*
- *abba*
- *abba*

Exercice 1.1.7. (*)

Donner la borne la plus basse possible du nombre de sous-mots d'un mot w . Donner un mot dont le nombre de sous-mots est exactement la borne donnée.

Correction. Pour construire l'ensemble des sous-mots d'un mot w , on choisit de garder ou non chaque lettre du mot. On a donc $2^{|w|}$ choix. On a d'ailleurs, pour énumérer l'ensemble des sous-mots de l'exercice précédent, "généralisé" la suite des séries de 5 bits (00000, 00001, 00010, 00011, etc) qu'on a collées sur *abba*.

Il peut y avoir des répétitions, comme dans l'exercice précédent, ce $2^{|w|}$ n'est donc qu'une borne maximale, cependant atteinte par un mot comme *abc*.

Exercice 1.1.8. (*) Dans l'exercice 1.1.1, on demande le nombre exact de préfixes et suffixes d'un mot, alors que dans les exercices 1.1.3 et 1.1.7, on demande une borne, pourquoi ?

Correction. Le nombre de préfixes et de suffixes est toujours le même, puisqu'on n'y trouve pas de problèmes de répétitions, contrairement aux facteurs et sous-mots (cf. les exercices associés).

1.2 Langage

Chapter 2

Expressions régulières

2.1 Lexique et idée générale

2.1.1 Les lettres et ϵ , la base

2.1.2 $.$, la concaténation

2.1.3 $*$, l'itération

Exercice 2.1.1. Donner 5 autres mots appartenant au langage dénotée par l'expression de l'exemple ??.

Exercice 2.1.2. Pourquoi le changement de formulation dans les exemples ?? et ?? par rapport aux exemples précédents ("c'est à dire $\{x, y, z\}$ " qui devient "contenant notamment x, y ou z ") ?

2.1.4 $+$, la disjonction

Exercice 2.1.3. Donner un mot acceptant deux dérivations avec la regex de l'exemple ?? (justifier en donnant les dérivations). Existe-t-il un autre mot admettant plusieurs dérivations ?

Exercice 2.1.4. Existe-t-il un mot acceptant plusieurs dérivations pour la regex de l'exemple ?? ?

Exercice 2.1.5. Donner un mot accepté par la regex de l'exemple ?? mais pas celle de l'exemple ??. Est-il possible de trouver un mot qui, à l'inverse, est accepté par la deuxième mais pas la première ?

Exercice 2.1.6. (*) Exprimer, en langue naturelle et de façon concise, le langage dénoté par la regex de l'exemple ??. Traduire ensuite ce langage en une regex non-ambiguë, c'est-à-dire où il n'y aura qu'une dérivation pour chaque mot.

2.2 Syntaxe

2.3 Sémantique

2.3.1 Les cas de base

2.3.2 Sémantique de la concaténation

2.3.3 Sémantique de la disjonction

2.3.4 Sémantique de l'itération

2.4 Mise en application

2.4.1 Quelques astuces

Exercice 2.4.1. Donner une *regex* pour les mots qui commencent par *a*.

Exercice 2.4.2. Donner une *regex* pour les mots qui finissent par *b*.

Exercice 2.4.3. Donner une *regex* pour les mots qui commencent par *a* finissent par *b*.

Exercice 2.4.4. Donner une *regex* pour les mots de longueur paire.

Exercice 2.4.5. Donner une *regex* pour les mots de longueur impaire qui contiennent au moins 4 lettres.

Exercice 2.4.6. Donner une *regex* pour les mots de longueur impaire, qui contiennent au moins 4 lettres, comment par *a* et finissent par *b*.

2.4.2 Syntaxe en pratique